개인적인 공부를 위해서 필요한 내용을 퍼온 것입니다. 출처는 남겨놓았습니다.

Decision Tree (의사결정 나무) 개념 정리

[의사결정 나무(Decision Tree) 쉽게 이해하기 - 아무튼 워라밸 (hleecaster.com)]

의사결정 나무(Decision Tree)는 각 데이터들이 가진 속성들로부터 패턴을 찾아내서 분류 과제를 수행할 수 있도록 하는 지도학습 머신러닝 모델이다.

의사결정 나무란 무엇인가

예를 들면 이런 거다.

시험에서 A를 받은 데이터를 초록색 동그라미로 표현했다고 하자.

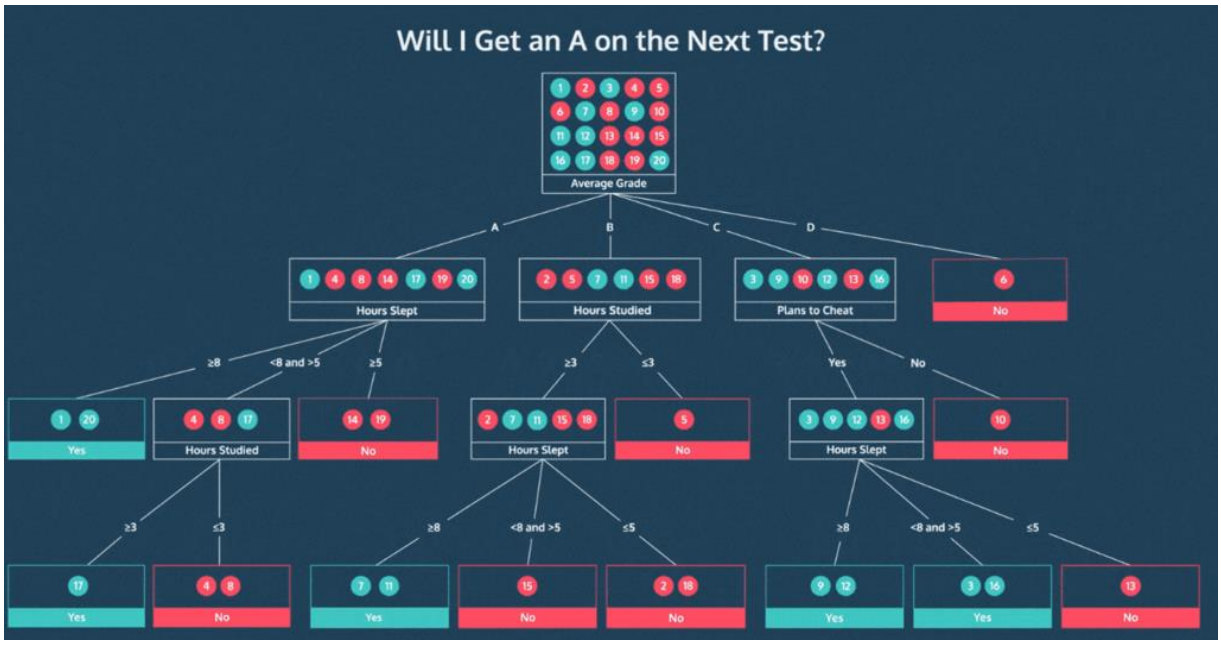

의사결정 나무는 대체 어떤 사람들이 그 A를 받았는지 나름의 기준이나 체크리스트(?) 같은 걸 만들어준다.

그래서 새로운 데이터가 들어오면 그 체크리스트를 바탕으로 하나씩 질문하고 (예를 들면 잠을 몇시간 잤냐, 공부는 몇 시간 했냐 등) 거기서 나온 답에 대한 다음 나무 줄기를 따라가다가 결국에는 '이건 어떤 레이블이겠구나'라고 분류를 해줄 수 있게 되는 것 일종의 스무고개 같은 거라 생각하면 편하다.

scikit-learn 사용법

파이썬 라이브러리 scikit-learn 을 사용하면 쉽게 트리를 만들 수 있다.

```
from sklearn.tree import DecisionTreeClassifier

classifier = DecisionTreeClassifier()

classifier.fit(training_points, training_labels)
```

학습 데이터를 기반으로 트리를 생성할 때는 `.fit()` 메서드를 사용하면 끝이다. 다만, 의사결정 트리에서는 만약 데이터가 문자열로 이루어져 있다면 이걸 숫자로 map 해서 넣어주는 게 좋다. 예를 들어 {“low”: 1, “mid”: 2, “high”: 3} 이런 식으로.

이제 새로운 데이터가 있을 때 예측을 해볼 수도 있고,

```
predictions = classifier.predict(test_data)
```

미리 테스트 세트를 나눠놓았다면 분류 정확도를 확인해볼 수도 있다.

```
print(classifier.score(test_data, test_labels))
```

한계 1.

그 순간만 보면 최선의 분할이 아니지만 이어서 나타나는 속성들에서 더 나은 분할을 발견하면 결과적으로 **더 좋은 트리를 만들 수도 있는데, 순간의 선택 때문에 그 가능성을 배제해버린다**는 뜻이다.

한계 2.

또 다른 문제는 의사결정 나무가 학습 데이터에 **오버피팅** 한다는 거다. 트리의 구조가 훈련 데이터에 너무 의존적이라 현실의 데이터를 정확하게 나타내지 못한다는 뜻이다. 일반적으로 **나무가 커질수록** 학습 데이터에 알맞게 모델이 만들어져서 현실 데이터로 일반화(generalization)하기 어려워지는 경향이 있다

Random Forest(랜덤 포레스트) 개념 정리

R (16) - 랜덤 포리스트 :: The best motivation is just doing it (tistory.com)

Decision Tree 는 overfitting 될 가능성이 높다는 약점을 가지고 있습니다. 가지치기를 통해 트리의 최대 높이를 설정해 줄 수 있지만 이로써는 overfitting 을 충분히 해결할 수 없습니다. 그러므로 좀더 일반화된 트리를 만드는 방법을 생각해야합니다. 이는 Random Forest(랜덤 포레스트)의 기원이 되는 아이디어입니다. Random forest 는 ensemble(앙상블) machine learning 모델입니다. 여러개의 decision tree 를 형성하고 새로운 데이터 포인트를 각 트리에 동시에 통과시키며, 각 트리가 분류한 결과에서 투표를 실시하여 가장 많이 득표한 결과를 최종 분류 결과로 선택합니다. 랜덤 포레스트가 생성한 일부 트리는 overfitting 될 수 있지만, 많은 수의 트리를 생성함으로써 overfitting 이 예측하는데 있어 큰 영향을 미치지 못 하도록 예방합니다. 이번 포스팅에서는 랜덤 포레스트에 대해서 알아봅시다.

Decision Tree 는 overfitting 될 가능성이 높다는 약점을 가지고 있습니다. 가지치기를 통해 트리의 최대 높이를 설정해 줄 수 있지만 이로써는 overfitting 을 충분히 해결할 수 없습니다. 그러므로 좀더 일반화된 트리를 만드는 방법을 생각해야합니다. 이는 Random Forest(랜덤 포레스트)의 기원이 되는 아이디어입니다.

Random forest 는 ensemble(앙상블) machine learning 모델입니다. 여러개의 decision tree 를 형성하고 새로운 데이터 포인트를 각 트리에 동시에 통과시키며, 각 트리가 분류한 결과에서 투표를 실시하여 가장 많이 득표한 결과를 최종 분류 결과로 선택합니다.

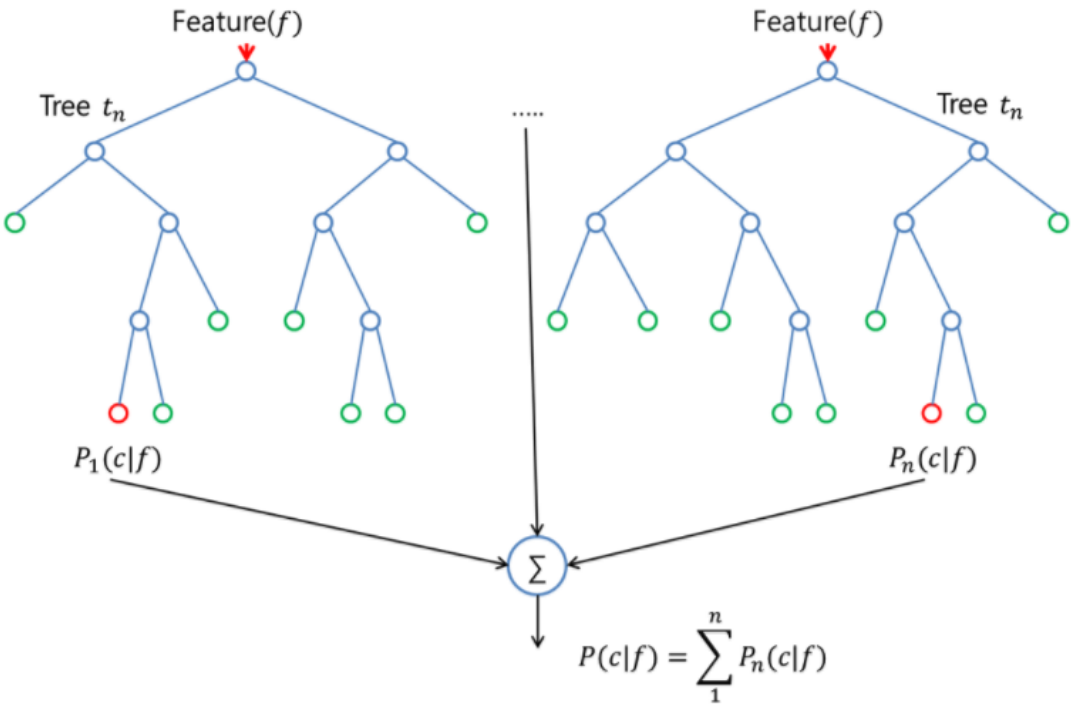

Source: Analytics Vidhya

랜덤 포레스트가 생성한 일부 트리는 overfitting 될 수 있지만, 많은 수의 트리를 생성함으로써 overfitting 이 예측하는데 있어 큰 영향을 미치지 못 하도록 예방합니다. 이번 포스팅에서는 랜덤 포레스트에 대해서 알아보도록 하겠습니다.

Bagging

랜덤 포레스트는 제일 먼저 *bagging* 이라는 과정을 거칩니다. Bagging 은 트리를 만들 때 training set 의 부분집합을 활용하여 형성하는 것을 말합니다. 예를 들어, training set 에 `1000` 개의 데이터가 존재한다고 가정하면 각 트리를 생성할 때 `100` 개의 데이터만 임의로 선택하여 트리를 만드는데 활용할 수 있는 것입니다. 즉 모든 트리는 각기 다른 데이터를 바탕으로 형성되지만 모두 training set 의 부분집합입니다.

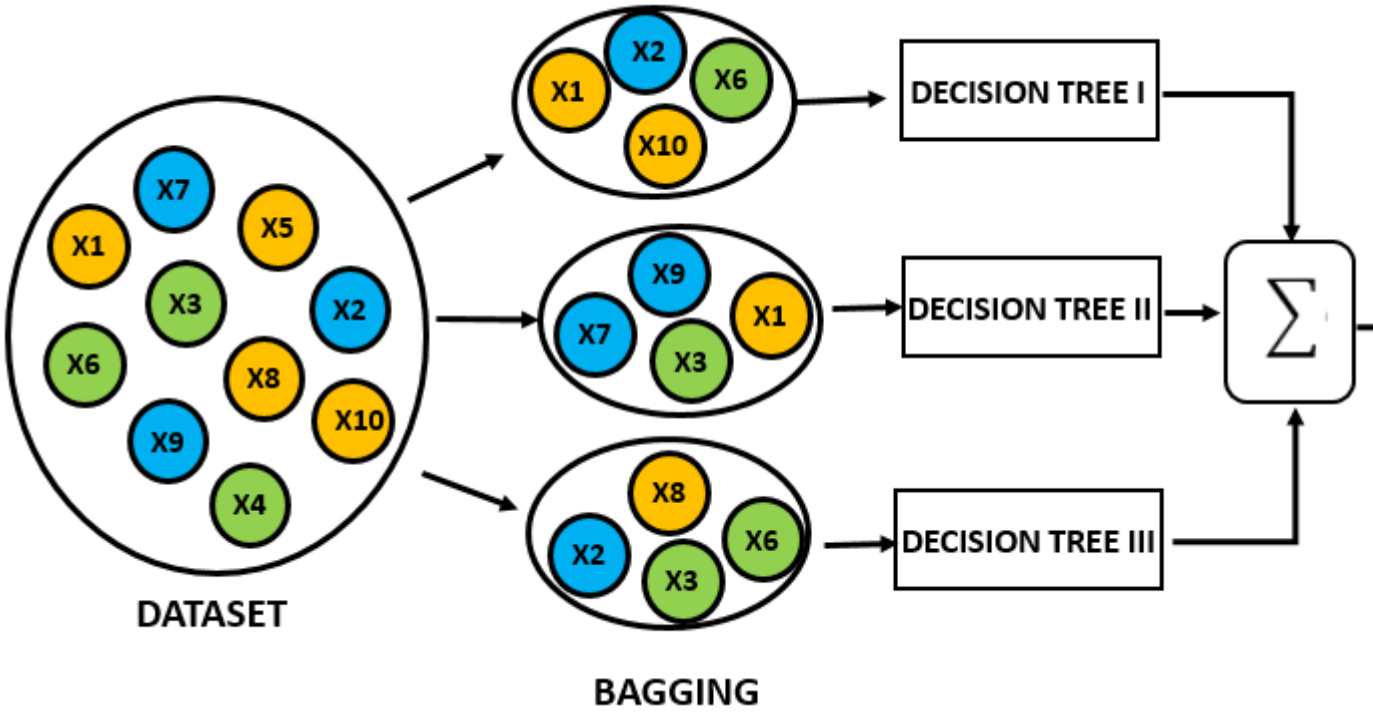

Source: Medium

이렇게 `100` 개의 데이터를 임의로 선택할 때 한가지 중요한 것은 바로 중복을 허용한다는 것입니다(with replacement). 이렇게 중복을 허용함으로써 `1000` 개의 training set 에서 `100` 개만 뽑기보다 `1000` 개씩 매번 뽑아도 unique 한 데이터셋을 형성할 수 있으므로 `N` 개의 training set 이 있다면 임의로 `N` 개의 데이터를 중복을 허용하여 선택함으로써 각 트리를 형성합니다.

Bagging Features

랜덤 포레스트는 트리를 형성할 때 데이터셋에만 변화를 주는 것이 아닌 feature 를 선택하는데 있어서도 변화를 줍니다. Feature 를 선택할때도 기존에 존재하는 feature 의 부분집합을 활용합니다. 예를 들어, 자동차 데이터셋에 다음과 같은 feature 들이 있고 이를 통해 자동차의 등급(`very good`, `good`, `acceptable`, `unacceptable`)을 분류한다고 생각해봅시다.

- 가격
- 유지 보수 비용
- 문의 개수
- 탑승 인원 수
- 트렁크 사이즈

- 안전 등급

위 데이터를 제일 처음 분류할 때, 고려할 feature 를 임의로 선택하여 가격과 문의 개수, 그리고 안전 등급 3 개의 feature 중에 선택할 수 있습니다. 여기서 선택된 best feature 로 데이터를 분류한 뒤에는 마찬가지로 고려할 feature 를 임의로 선택하여 유지 보수 비용과 문의 개수, 그리고 트렁크 사이즈 3 개의 feature 중에 선택할 수 있습니다. 이러한 과정을 트리가 만들어질 때 까지 반복합니다.

위 예에서는 단지 `3` 개의 feature 만을 임의로 선택하였는데 이는 예시로 든 feature 수가 적기 때문이고, 일반적으로 `M` 개의 feature 가 존재할 때, 임의로 선택하는 feature 의 수는 $\sqrt{M}$ 을 활용합니다. 즉, `25` 개의 feaure 가 존재한다면 임의로 `5` 개의 feature 를 선택하고 그 중에서 가장 information gain 이 높은 feature 를 선택하여 데이터를 분류하게 됩니다.

Classify

여러개의 트리를 형성하였다면 이제 classify 를 수행할 수 있습니다. 예를 들어, `8` 개의 트리를 형성하고 임의의 자동차 데이터를 각 트리에 전달하였을 때 나온 결과가 다음과 같다고 가정해봅시다.

```
["very good", "very good", "good", "very good", "acceptable", "very good", "good",
"very good"]
```

위 결과에서 `very good` 이 `5` 번 등장하여 가장 많은 득표수를 나타냈으므로 임의의 자동차는 `very good` 으로 분류될 것입니다. Test 단계에서는 모든 데이터셋에 대해서 위 과정을 거치게 되고, 그렇게 나온 결과와 ground truth 를 비교하여 accuracy 를 측정하게 됩니다.